

Aktualne Problemy Informatyki Stosowanej - Geoinformatyka II st.

Zadanie 4 – RAG w zastosowaniach geoinformatycznych

Cel Projektu:

Celem projektu jest zaprojektowanie i (na wyższe oceny) zaimplementowanie systemu typu RAG (Retrieval-Augmented Generation), czyli systemu generującego odpowiedzi na podstawie zewnętrznych źródeł wiedzy.

System będzie pełnił rolę eksperta w wybranym zagadnieniu z zakresu geoinformatyki. Należy znaleźć kilka publikacji naukowych dotyczących wybranego tematu oraz zaprojektować system w taki sposób, żeby model mógł korzystać z tych publikacji (w formie plików PDF) jako kontekstu podczas generowania odpowiedzi.

Na maila proszę przesłać:

- sprawozdanie w formie pdf
- notebooki z kodem
- ewentualnie dodatkowe pliki

Tytuł maila: APIS_2026_projekt_2_imie_nazwisko Termin wystania projektu do 27.04

Sposób oceniania:

Ocena 3.0: opisowe przedstawienie architektury systemu RAG (samo sprawozdanie) -> punkty 1-5 z sekcji *Sprawozdanie* (jeżeli jest pytanie np. jaki model embeddingowy został wybrany to należy opisać jaki model by się wybrało i dlaczego).

Ocena 3.5: implementacja podstawowej wersji systemu RAG

- wczytywanie dokumentów (przykładowo w formacie PDF)
- generowanie embeddingów dla dokumentów (użyć przetrenowanego modelu)
- implementacja mechanizmu retrieval
- generowanie odpowiedzi z wykorzystaniem kontekstu
- system zaimplementowany jako klasa

Ocena 4.0: to co na ocenę 3.5 + dodatkowo

- podział dokumentów na chunki

Ocena 4.5: to samo co na ocenę 4.0 + dodatkowo:

- zapisywanie embeddingów w vector store

Ocena 5.0: wszystko co z oceny 4.5 + dodatkowo:

- ewaluacja jakości odpowiedzi (analiza możliwych podejść, które jest najlepsze w naszym przypadku, np. BLUE, ROUGE, Faithfulness, LLM-as-a-Judge)

Sprawozdanie:

W sprawozdaniu należy zamieścić opis wszystkich kroków wykonanych w ramach realizacji zadania na daną ocenę oraz wyjaśnić, dlaczego w poszczególnych etapach podjęto konkretne decyzje.

Dodatkowo w sprawozdaniu powinny znaleźć się następujące informacje i odpowiedzi na pytania:

1. Zastosowanie systemów RAG
 - czym jest RAG i czym różni się od chatbota
 - jakie problemy zwykłych chatbotów rozwiązuje
2. Architektura systemu RAG
 - opisać schemat przepływu danych
 - wytłumaczyć poszczególne komponenty i koncepty związane z systemem RAG
 - a) loader dokumentów
 - b) chunking
 - c) embeddingi
 - d) vector store
 - e) retriever
3. Generowanie odpowiedzi
 - w jaki sposób generowany jest prompt
4. Embeddingi
 - jaki model embeddingowy został wybrany i dlaczego
 - w jaki sposób embeddingi reprezentują tekst
 - jak embeddingi wpływają na jakość retrieval
5. Retrieval
 - jak działa wyszukiwanie podobieństwa
 - jaka metryka podobieństwa została użyta
6. Chunkowanie dokumentów (od 4.0 w górę)
 - dlaczego dokumenty dzielone są na fragmenty
 - jak dobrano długość chunka
 - jakie metody chunkowania zastosowano
 - jakie są inne/alternatywne metody chunkowania
7. Vector Store (od 4.5 w górę)
 - czym jest baza wektorowa
 - jakie rozwiązanie zostało wykorzystane (np. FAISS)
 - W jaki sposób przechowywane są embeddingi i metadane
8. Ewaluacja odpowiedzi (od 5.0)
 - jakie metryki ewaluacji wykorzystano (ręczne i automatyczne)

- jakie są metryki ewaluacji i w jakich przypadkach najlepiej je stosować

9. Podaj przykłady wyników działania systemu i oceń ich jakość.