

Aktualne Problemy Informatyki Stosowanej - Geoinformatyka II st.

Zadanie 6 – Generator obrazów (text-to-image)- Stable Diffusion

Cel Projektu:

Celem projektu jest przygotowanie pipelineu treningowego oraz dotrenowanie modelu Stable Diffusion w celu generowania obrazów wybranych ras psów.

Inicjalizacja projektu:

Proszę pobrać przy użyciu poniższego kodu zbiór zdjęć ras konkretnych psów:

```
!pip install kaggle
```

```
!kaggle datasets download -d jessicali9530/stanford-dogs-dataset
```

Następnie przy użyciu poniższego kodu należy pobrać repozytorium z kodem do modelu Stable Diffusion:

```
!git clone https://github.com/huggingface/diffusers
```

```
%cd diffusers/examples/dreambooth
```

W ramach treningu proszę wybrać 5 ras psów i dotrenować model Stable Diffusion (np. metodą LoRA lub DreamBooth) w taki sposób, żeby poprawić jakość generacji modelu na tych konkretnych rasach. Zbiór danych stanford-dogs-dataset składa się z dwóch folderów: annotations oraz images. Trening polega na podawaniu do modelu pary: obrazek i prompt, np. <zdjęcie psa rasy beagle> i prompt: „photo of beagle dog”. W ten sposób model uczy się powiązania między cechami wizualnymi obrazu, a tekstową reprezentacją danej rasy. Prompty powinny być jasne i mieć spójną strukturę.

Na maila proszę przesyłać:

- sprawozdanie w formie pdf
- notebooki z kodem
- ewentualnie dodatkowe pliki

Tytuł maila: APIS_2026_projekt_4_imie_nazwisko

Termin wystania projektu do 25.05

Wprowadzenie do tematyki:

Modele dyfuzyjne (takie jak Stable Diffusion) uczą się generować obrazy poprzez stopniowe usuwanie szumu z danych losowych. Modele tego typu dobrze radzą sobie z generowaniem ogólnych obrazów, jednak w przypadku bardziej specyficznych lub wyspecjalizowanych zadań (np. generowania konkretnych ras psów) ich jakość może być ograniczona.

W takich przypadkach kluczowe staje się zagadnienie technik fine-tuningu i transfer learningu, które pozwalają dostosować model ogólny do bardziej wyspecjalizowanych zastosowań.

W kontekście tego projektu model bazowy może generować realistyczne obrazy psów, jednak jego zdolność do odwzorowania cech charakterystycznych konkretnych ras może być ograniczona. Dotrenowanie modelu na dedykowanym zbiorze danych pozwala poprawić tę zdolność i uzyskać bardziej precyzyjne rezultaty.

Jest wiele sposobów dotrenowywania modeli generatywnych obrazów, takich jak Stable Diffusion.

Metoda LoRA polega na tym, że zamiast modyfikować wszystkie parametry modelu, zamrażamy oryginalne wagi sieci, a uczymy tylko dodatkowe małe macierze o niskim rzędzie, które są potem uwzględniane w warstwach uwagi. W ten sposób oryginalny model jest nietknięty, a dodatkowe wagi pozwalają modelowi lepiej dostosować się do nowego zagadnienia. Finalnie nowa waga to $W + \Delta W$ gdzie ΔW to waga wyliczona w ramach treningu LoRA.

Alternatywnym podejściem jest metoda DreamBooth, która polega na finetuningu całego modelu, lub dużej jego części. Polega na uczeniu modelu nowego konceptu poprzez przypisanie do niego unikalnego tokenu w promptach np. *sks pies*. W ten sposób model uczy się łączyć obraz z nowym tokenem.

Trening modelu można wykonać na dwa sposoby

1. Przy użyciu biblioteki PyTorch, mając pełny dostęp do architektury modelu. Możemy wtedy modyfikować loss function, metodę optymalizacji etc.
2. Przy użyciu HuggingFace Accelerate – dużo prostsze podejście, polega na odpaleniu polecenia `accelerate launch <ścieżka do funkcji treningowej>` w terminalu. Jest to raczej standardowe podejście we współczesnych pipeline'ach ML.

Sposób oceniania:

Ocena 3.0: opisowe przedstawienie procesu dotrenowywania modelu Stable Diffusion do generowania obrazów konkretnych ras psów (samo sprawozdanie) -> punkty 1-8 z sekcji *Sprawozdanie*.

Ocena 3.5: to co na ocenę 3.0 + dodatkowo:

- dotrenowanie modelu Stable Diffusion przy użyciu jednej z metod: LoRA lub DreamBooth. UWAGA: przy użyciu operatora *accelerate launch* może być konieczne

zmodyfikowanie funkcji treningowej w pliku .py. Na wyjściu należy przedstawić wygenerowane obraz przed i po treningu i porównać wyniki.

Ocena 4.0: to co na ocenę 3.5 + dodatkowo

- dotrenowanie modelu przy użyciu drugiej metody i porównanie wyników(jakość wizualna, zgodność z promptem, różnorodność obrazów w obrębie tej samej rasy, ewentualne artefakty, sprawdzenie czy model nie uczy się obrazów na pamięć).

Ocena 5.0: to samo co na ocenę 4.0 + dodatkowo:

- trening trzech wariantów modelu:

1. jedna LoRA trenowana na wszystkich 5 rasach jednocześnie
2. osobne modele LoRA trenowane niezależnie dla każdej klasy (5 modeli)
3. model trenowany metodą DreamBooth

- porównanie wszystkich podejść

Sprawozdanie:

W sprawozdaniu należy zamieścić opis wszystkich kroków wykonanych w ramach realizacji zadania na daną ocenę oraz wyjaśnić, dlaczego w poszczególnych etapach podjęto konkretne decyzje.

Dodatkowo w sprawozdaniu powinny znaleźć się następujące informacje i odpowiedzi na pytania:

1. Architektura i pipeline:
 - Opisz architekturę systemu treningowego wykorzystaną w projekcie(przepływ danych, sposób przygotowania promptów, sposób trenowania modelu)
2. Modele generatywne:
 - Czym są modele dyfuzyjne i na jakiej zasadzie działają
 - Jakie istnieją inne podejścia do generowania obrazów (np. GAN lub VAE) i czym różnią się od modeli dyfuzyjnych)
3. Stable Diffusion
 - Opisz architekturę modelu Stable Diffusion
4. Transfer learning
 - Na czym polega transfer learning w modelach głębokich
 - Wyjaśnij pojęcia zamrażania warstw
 - Od czego zależy wybór (które i ile) zamrażanych warstw
5. LoRA
 - Wytłumacz swoimi słowami na czym polega metoda LoRA i czym różni się od klasycznego fine-tuningu
6. LoRA vs DreamBooth
 - Którą metodą zastosowano w projekcie
 - Kiedy należy stosować metodę LoRA a kiedy DreamBooth
7. Trening LoRA

- Na czym polega różnica między trenowaniem LoRA na wielu klasach i osobnymi modelami LoRA dla każdej z klas. Jakie są wady i zalety obu podejść

8. Hiperparametry:

- Jakie hiperparametry i jakie ich wartości zostały użyte w ramach treningu
- Jak poszczególne hiperparametry wpływają na jakość i na sam trening

9. Wyniki i analiza

- Zaprezentuj i przeanalizuj wyniki modelu przed przetrenowaniem i po przetrenowaniu